

Ejercicio 3. Lectura y resumen de tres artículos

Artículo 1. Datos sísmicos.

Villa Vargas, J. M., Hurtado Avilés, G., y Climent Hernández, J. A. (2026). Cuando México tiembla: la historia contada por los datos. *AZCATL Revista de Divulgación de la Ciencia, la Ingeniería y la Innovación*, 4(6), 28–33.

El artículo aborda la problemática de que, aunque el Servicio Sismológico Nacional (SSN) genera información detallada y valiosa sobre la intensa actividad sísmica en México (país ubicado en el Cinturón de Fuego del Pacífico y atravesado por cinco placas tectónicas donde el 70% del territorio expone riesgo sísmico), esta información suele ser altamente técnica, visualmente poco amigable y difícil de manejar para la población general o los investigadores. Esto importa porque la falta de accesibilidad a los datos limita la cultura de la prevención, la gestión gubernamental eficiente y la investigación científica ante desastres naturales recurrentes en zonas densamente pobladas como el Valle de México o Guadalajara.

Los datos provienen del catálogo de sismos del Servicio Sismológico Nacional (SSN) con más de 300,000 registros desde 1900, complementados con datos demográficos y económicos del Instituto Nacional de Estadística y Geografía (INEGI), específicamente del Censo de Población y Vivienda 2020 y los Censos Económicos 2024.

Procesamiento y ETL: Para convertir los datos dispersos en información útil, se desarrolló un programa en Python que examina los archivos CSV para detectar campos vacíos, coordenadas inconsistentes o formatos incompatibles, eliminando los registros no válidos. Posteriormente, este programa genera código SQL que se carga en una base de datos PostgreSQL, estructurando la información bajo un modelo de almacén de datos (*data warehouse*) que integra sismos, población y economía. El despliegue de los servicios se gestiona mediante un servidor web Apache con PHP 8, interfaces en HTML5, CSS3, Bootstrap y JavaScript, mapas interactivos basados en OpenStreetMap, y el uso de Docker Compose para simplificar su ejecución en contenedores virtuales.

La información validada se organiza y almacena en una base de datos PostgreSQL configurada bajo una arquitectura de almacén de datos (*data warehouse*). Esta estructura permite unificar y relacionar de forma coherente las dimensiones de tiempo, ubicación geográfica, variables demográficas de población y datos económicos procedentes del INEGI con los eventos sísmicos registrados por el SSN.

Gracias a su interfaz web interactiva y sus opciones de filtros personalizados, el sistema permite responder interrogantes analíticas tales como:

- ¿Qué localidades o zonas densamente pobladas se encuentran expuestas y cercanas a los epicentros de sismos de determinada magnitud (por ejemplo, de 2 grados o mayores)?
- ¿Cuál es el comportamiento estadístico de la sismicidad en un estado específico durante un año determinado, incluyendo la distribución de magnitudes, la correlación entre magnitud y profundidad, o la frecuencia de sismos por mes?
- ¿Cuál fue el alcance territorial en distancia de un evento sísmico y qué localidades afectó directamente mediante el uso de mapas de calor sísmico?
- ¿Cómo se cruzan los datos de población potencialmente afectada y producción económica frente a la magnitud de los sismos mediante reportes a la medida?

Limitaciones: Los autores señalan que la implementación y ejecución del sistema puede llegar a ser compleja o complicada para usuarios con poco o nulo dominio de las herramientas técnicas empleadas, dificultad que buscaron mitigar mediante el empaquetado de contenedores con Docker Compose.

Trabajo futuro: Como líneas de evolución y mejora, los autores proponen:

1. Habilitar visualizaciones cartográficas en 3D.
2. Incorporar nuevas fuentes de datos oficiales.
3. Integrar el sistema con plataformas de alerta temprana.

Artículo 2. Consumo de agua en la Ciudad de México.

Velázquez Arrieta, E. U., Pulido Morales, O. F., García López, E., Hernández Martínez, C. A., y Hurtado Avilés, G. (en prensa). Territorial information retrieval from heterogeneous open data through the construction of a data warehouse for water management in Mexico City. En *Advances in Computer Science Applications and Research*. Springer.

La Ciudad de México enfrenta una severa crisis hídrica agravada por la sobreexplotación de acuíferos, fugas en la red y el crecimiento poblacional. Aunque el Sistema de Aguas de la Ciudad de México (SACMEX) publica datos abiertos sobre el consumo, estos se encuentran en formatos dispersos y de difícil acceso, sin herramientas de consulta que faciliten la toma de decisiones basada en evidencias. Para resolver este problema, el artículo propone una metodología integral para transformar datos abiertos heterogéneos en un repositorio analítico estructurado y accesible.

Los datos provienen del portal de datos abiertos de la CDMX (específicamente del recurso de consumo de agua del primer semestre de 2019), complementados con series meteorológicas de Open-Meteo y bases cartográficas de OpenStreetMap. Debido a que los archivos CSV originales carecían de esquemas estandarizados y presentaban metadatos incompletos, los autores diseñaron un proceso de Extracción, Transformación y Carga (ETL) en Python y SQL. Este pipeline limpia los datos de manera determinista (descartando un 0.30% de registros con valores nulos en campos territoriales) y consolida un total de **70,886 registros** válidos.

Para estructurar la información, el sistema implementa un **modelo en estrella (star schema)** en PostgreSQL, el cual gira en torno a dos tablas de hechos (fact_consumo_agua y fact_clima) y tres dimensiones conformadas: tiempo (dim_tiempo), ubicación geográfica (dim_ubicacion) y nivel de desarrollo socioeconómico (dim_indice_des). Además, utilizando mapeos declarativos R2RML, la información relacional se proyecta de forma complementaria hacia un grafo de conocimiento validado bajo el vocabulario *RDF Data Cube*, lo que permite realizar consultas topológicas y de adyacencia espacial.

Gracias a esta arquitectura, el sistema expone una interfaz interactiva de consulta alojada en GitHub Pages que no requiere servidores backend. Permite responder preguntas concretas tales como:

- ¿cuál es el consumo total y promedio de agua desglosado por alcaldía, colonia y bimestre?
- ¿qué zonas presentan patrones de consumo atípico en comparación con su entorno para priorizar inspecciones técnicas?
- ¿qué colonias vecinas (a menos de 1.5 km) comparten patrones similares mediante recorridos en el grafo?

Los autores reconocen ciertas limitaciones en su trabajo: la cobertura temporal se restringe a tres bimestres de un solo año, el módulo de anomalías fue evaluado mediante perturbaciones sintéticas y no con registros reales de fugas, las colonias están representadas por centroides puntuales y no por polígonos exactos, y las asociaciones con el índice de desarrollo son de carácter estrictamente descriptivo. Como trabajo futuro, proponen materializar el grafo en un *triple store* persistente con un punto SPARQL público, incorporar polígonos vectoriales oficiales, alinear identificadores territoriales con otras fuentes municipales y reevaluar los algoritmos de detección con datos reales de fugas conforme estén disponibles.

Artículo 3. Obra pública municipal.

González Casiano, U., Maldonado Mejía, M. T., y Hurtado Avilés, G. (en prensa). A dimensional data warehouse for geospatial monitoring of municipal public works, with an evolution path toward a lakehouse architecture. En *Advances in Computer Science Applications and Research*. Springer.

La gestión de la infraestructura pública municipal en México suele fragmentarse en sistemas aislados o hojas de cálculo, lo que dificulta el análisis histórico, la detección temprana de retrasos y la participación ciudadana. Este artículo presenta el diseño y prototipo de un *Data Warehouse* dimensional para el monitoreo geoespacial de obras públicas municipales en Temascaltepec, Estado de México, complementado con almacenamiento de objetos (Cloudflare R2) para evidencias no estructuradas.

La arquitectura del sistema se divide en cuatro capas operativas: una capa de ingestión a través de una aplicación web basada en roles (directores, supervisores, secretarios, planeadores y ciudadanos), una API REST desarrollada en Flask/Python con 56 rutas y controles de acceso, una capa de almacenamiento híbrida (que combina PostgreSQL/Supabase con triggers automáticos para el versionado y Cloudflare R2 para archivos binarios), y una capa de presentación que incluye un visor geoespacial interactivo y vistas analíticas públicas.

En cuanto al modelado dimensional, el almacén implementa un esquema en estrella optimizado compuesto por dos tablas de hechos y diez dimensiones:

- **Tablas de Hechos:** fact_audit_events (registra eventos atómicos e inmutables particionados por año) y fact_work_monthly (instantánea periódica con grano de una fila por obra y mes).
- **Dimensiones (SCD):** Destaca el uso de cinco dimensiones de Tipo 2 (obras, regiones, empresas, personal y presupuesto) para mantener una trazabilidad histórica rigurosa mediante columnas de vigencia, tres de Tipo 1 y dos de Tipo 0.

El sistema expone seis vistas analíticas y un módulo de detección de anomalías sin estado que evalúa tres criterios operativos (C1: valores atípicos de costos, C2: retrasos extremos superiores a 120 días, y C3: inconsistencias entre el avance físico y financiero). En las pruebas de evaluación frente a causas latentes simuladas, la regla implementada alcanza una precisión de 0.46 con una recuperación de 0.35, mostrando que aunque resulta competitiva en presupuesto de alertas, presenta limitaciones específicas en la detección de sobreprecios. Asimismo, las pruebas de rendimiento demuestran que el almacén responde en milisegundos de un solo dígito gracias a su diseño estelar, concentrándose la latencia principalmente en la serialización de respuestas de la API.

Los autores reconocen como limitaciones la ausencia de un despliegue dinámico alojado permanentemente (enfocándose en un artefacto estático y código reproducible), el uso de datos sintéticos debido a restricciones de privacidad, y una estructura de almacenamiento de objetos centrada puramente en evidencias binarias y no en un formato de tabla abierta consultable directamente.

Como trabajo futuro, proponen evolucionar la capa de objetos hacia una arquitectura *lakehouse* completa empleando formatos como Apache Iceberg o Parquet consultados mediante motores ligeros (DuckDB o Trino), incorporar modelos de visión artificial para clasificar avances físicos, y alinear el esquema con estándares internacionales de transparencia como el OC4IDS.